# Agente de ahorro de TodoBarato

Consulta, escritura y razonamiento, con memoria y replanificación

ISY0101 Ingeniería de Soluciones con IA · Evaluación Parcial 2

Nicolas Estefania · Ariel Espinoza

# Un asesor de compras que deja registro

**1** **«Notebook para la universidad, hasta $400.000»**

Busca, compara tiendas, juzga el precio y guarda la lista

**2** **«Notebook gamer, hasta $300.000, avísame»**

No hay en ese precio: cambia de estrategia y deja una alerta

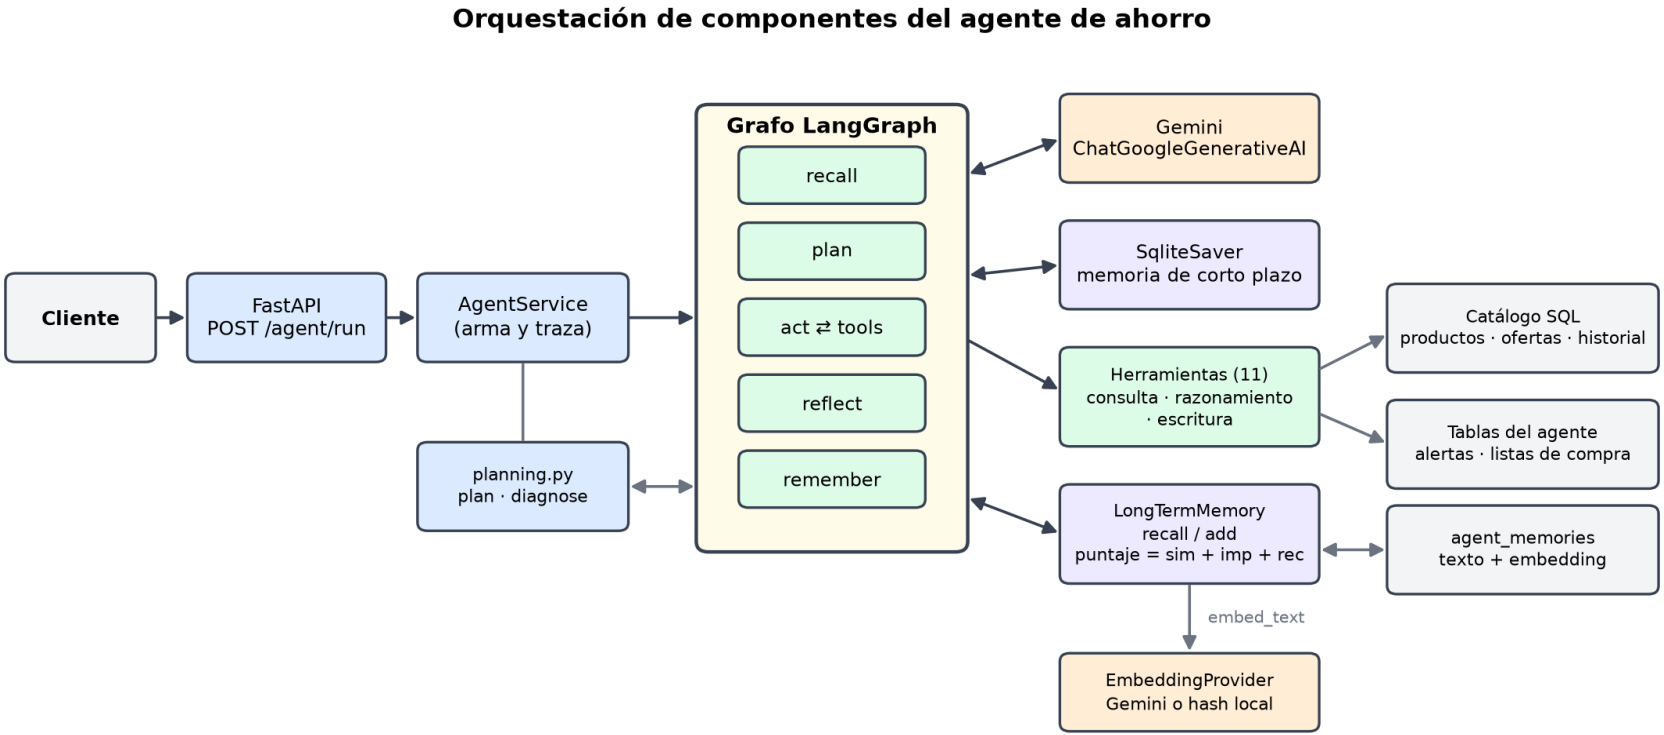
**3** **«Revisa mis alertas»**

Compara cada alerta con los precios de hoy

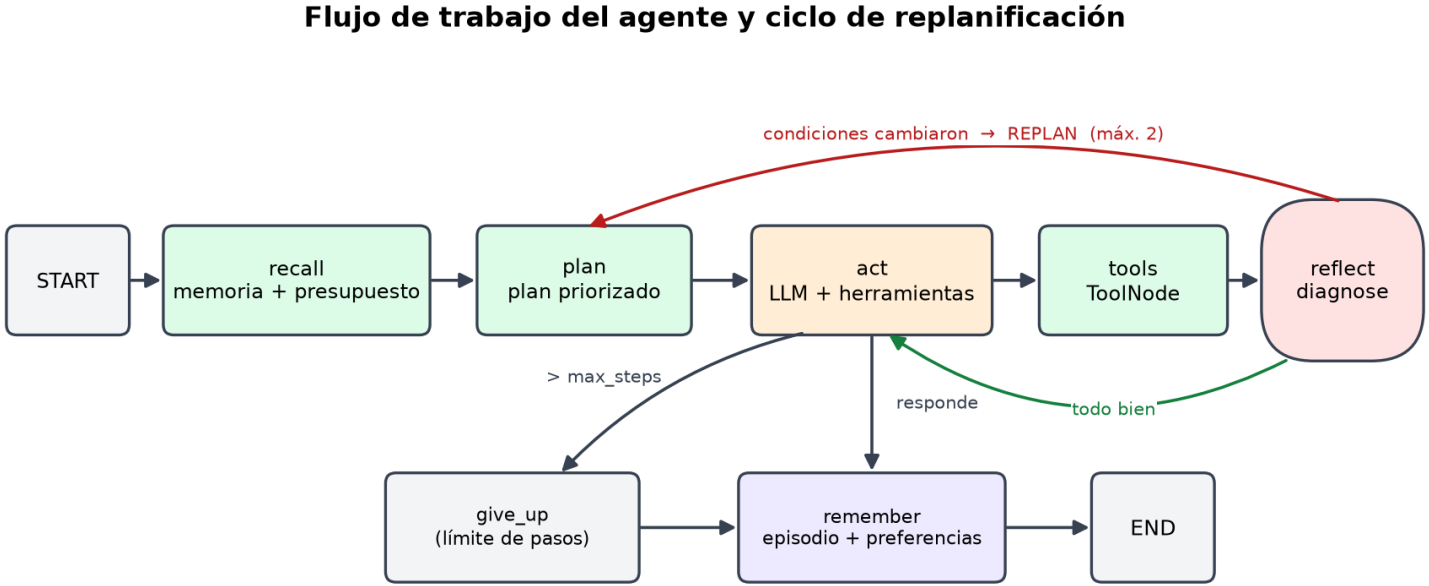
**4** **«Prefiero Samsung, no quiero Huawei»**

Lo recuerda en conversaciones futuras

# Orquestación de componentes



# Flujo del grafo y replanificación




**Diagnósticos que disparan un replan:**

sin_resultados · sobre_presupuesto · sin_stock · precio_alto (veredicto «esperar») · error_herramienta
Cada motivo replanifica una sola vez; el plan nuevo conserva los pasos ya hechos.

# Cinco diagnósticos cambian el plan

| Observación | Diagnóstico | Adaptación |
|---|---|---|
| Búsqueda con 0 resultados | **sin_resultados** | Términos más generales, sin filtro de precio |
| Todo cuesta más que el presupuesto | **sobre_presupuesto** | Gama inferior o alerta; informa cuánto falta |
| Todas las ofertas sin stock | **sin_stock** | Descarta y elige otra tienda |
| Tendencia dice «esperar» | **precio_alto** | No compra hoy; alerta al promedio histórico |
| Una herramienta falló | **error_herramienta** | Corrige parámetros y reintenta una vez |

# Memoria de corto y largo plazo

## Corto plazo

*Continuidad dentro de una tarea*

- Historial del hilo en el checkpointer de LangGraph
- SQLite en local, Postgres con varias réplicas
- Ventana de 24 mensajes + resumen de lo recortado
- Cada hilo atado a su usuario

## Largo plazo

*Conocimiento entre conversaciones*

- Preferencias, hechos y episodios con embedding
- Memoria núcleo: lo importante se carga siempre
- Búsqueda semántica; sin duplicados
- Aislada por usuario

**puntaje = 0,75 · similitud + 0,15 · importancia/5 + 0,10 · recencia**

# Demo en vivo: cinco historias

1

**Compra simple**

consulta → razonamiento → escritura

2

**Sin resultados**

replan ×2 y alerta de precio

3

**Precio inflado**

el historial dice «esperar»

4

**Otro día, otro hilo**

recuerda «Prefiero Samsung»

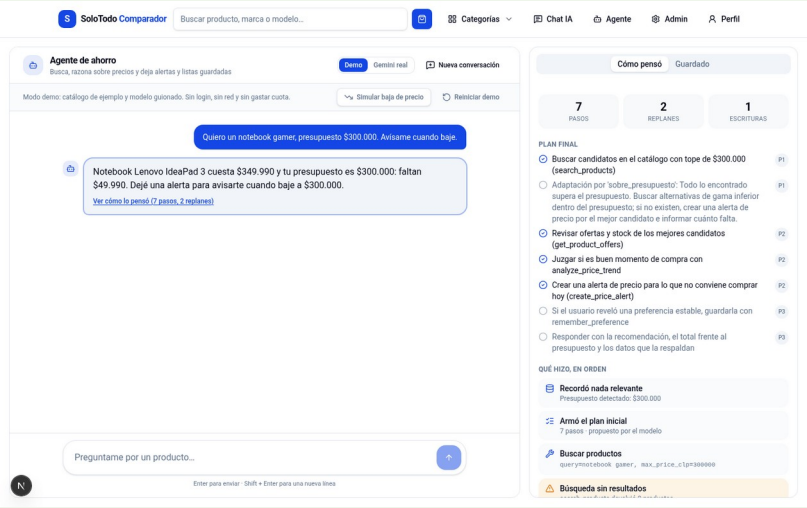
5

**Bajó el precio**

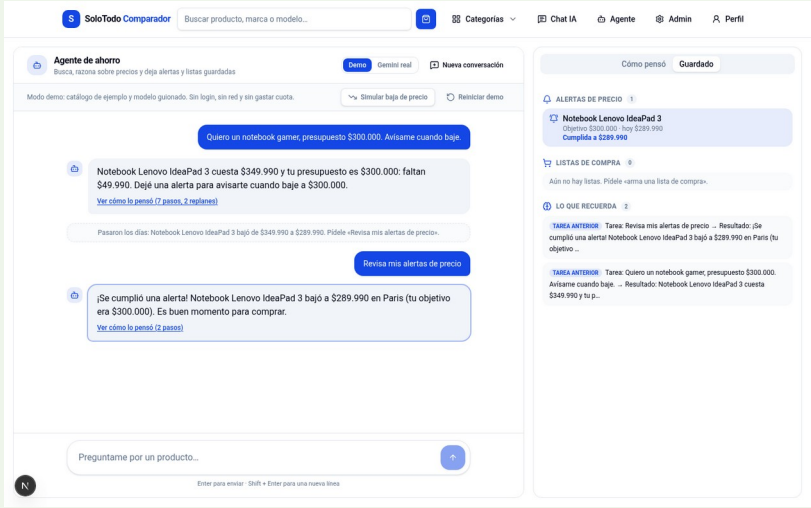
se cumple la alerta

```
.venv/bin/python scripts/demo_agente.py --live --embeddings gemini
```

# La pantalla: se ve cómo piensa




**Plan, herramientas y replanes en vivo**




**La alerta se cumple y queda guardada**

Modo demo en http://localhost:3000/agente?demo=1: sin login y sin gastar cuota

# Evidencia

**88**

pruebas del agente

**873**

pruebas en todo el repositorio

**11**

herramientas: consulta, razonamiento y escritura

**5**

diagnósticos que replanifican

**Gemini real:** historias 1 a 3 completas, con replan por sin_resultados, sobre_presupuesto y precio_alto

**Checkpointer:** dos conexiones distintas comparten un mismo hilo en Postgres 16 real

# Por qué estas decisiones

| | |
|---|---|
| **LangGraph** | el flujo tiene ciclo (reflect → plan), estado y checkpointer; el orquestador previo no guardaba estado |
| **Reglas en código** | diagnóstico, tendencia y presupuesto se prueban sin red: 88 pruebas |
| **Memoria núcleo** | con embeddings locales «Recomiéndame un celular» no recuperaba «Prefiero Samsung» |
| **Checkpointer Postgres** | varias réplicas comparten los hilos (probado con Postgres 16 real) |