Agente de ahorro de TodoBarato

Consulta, escritura y razonamiento, con memoria y replanificación

ISY0101 Ingeniería de Soluciones con IA · Evaluación Parcial 2

Nicolas Estefania · Ariel Espinoza

Un asesor de compras que deja registro

1 **«Notebook para la universidad, hasta $400.000»**

Busca, compara tiendas, juzga el precio y guarda la lista

2 **«Notebook gamer, hasta $300.000, avísame»**

No hay en ese precio: cambia de estrategia y deja una alerta

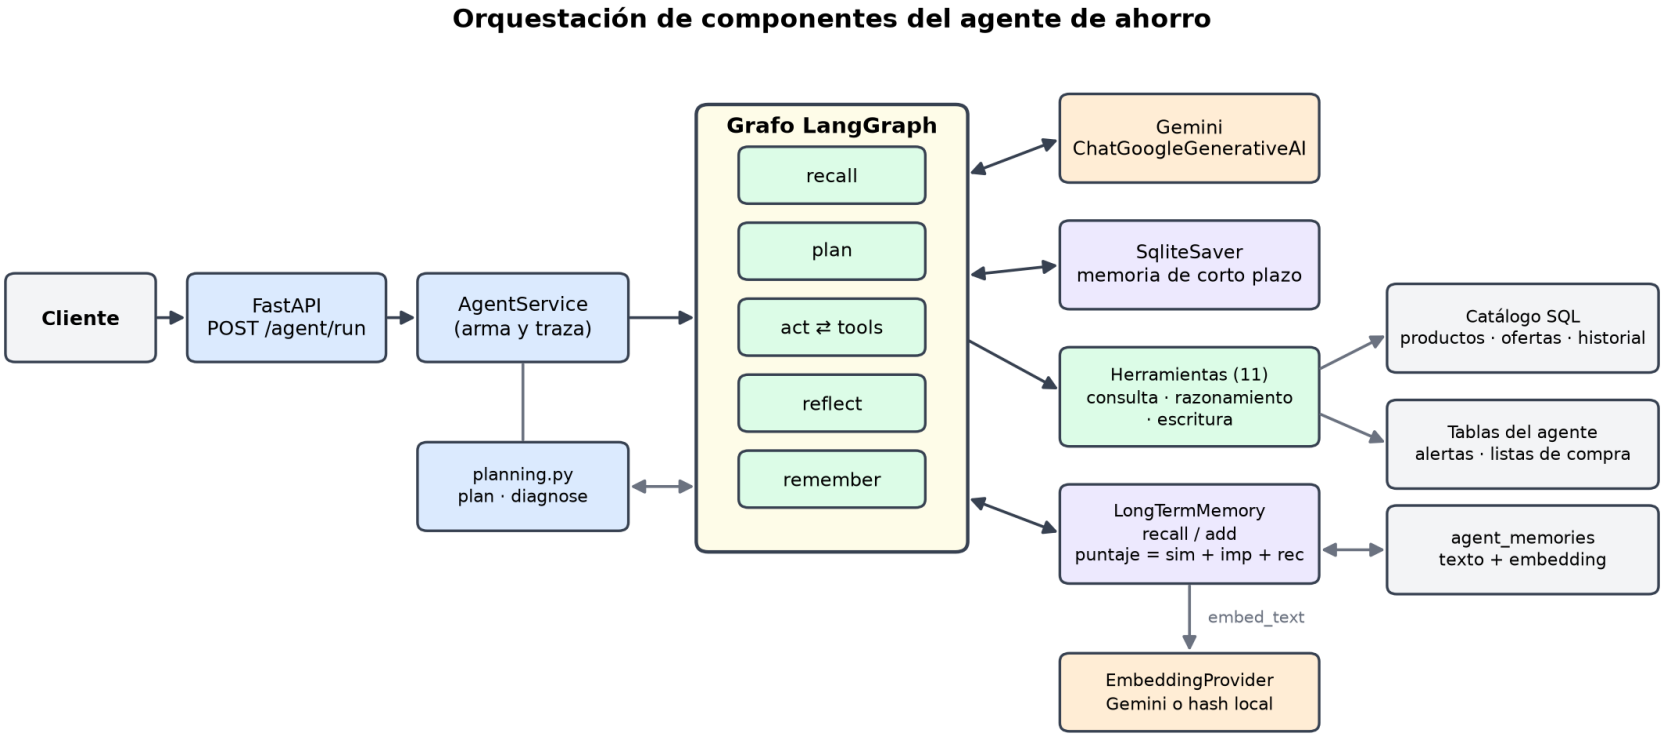
3 **«Revisa mis alertas»**

Compara cada alerta con los precios de hoy

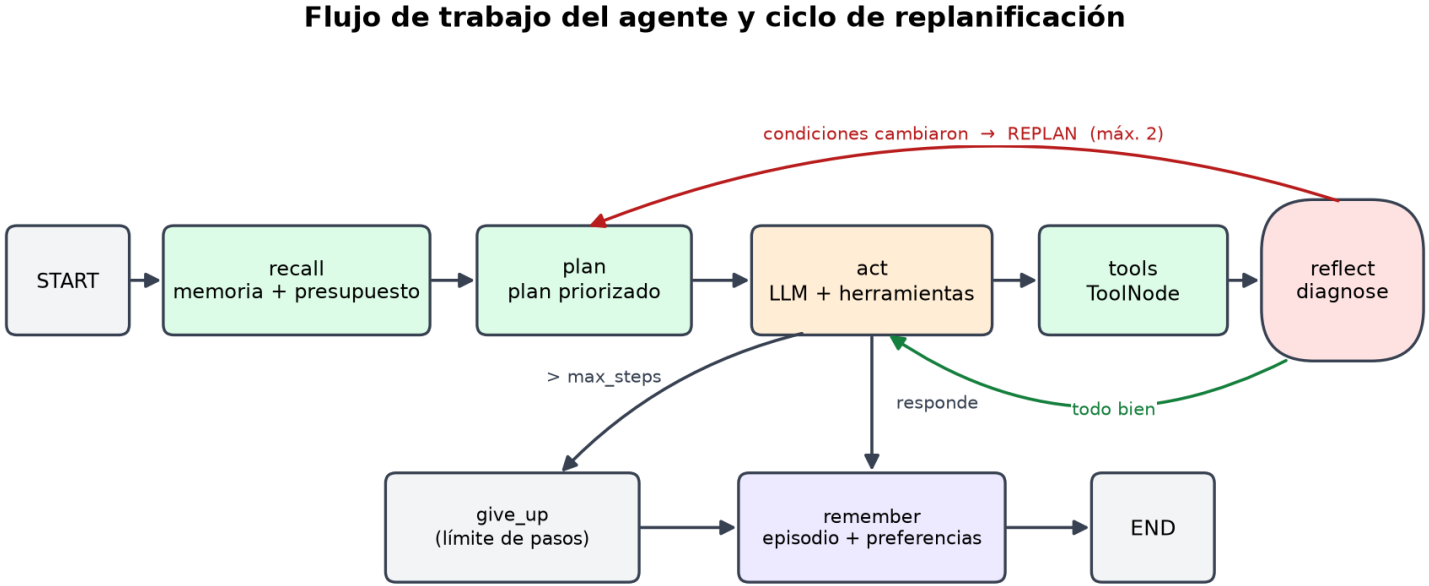
4 **«Prefiero Samsung, no quiero Huawei»**

Lo recuerda en conversaciones futuras

Orquestación de componentes



Flujo del grafo y replanificación



Diagnósticos que disparan un replan:

sin_resultados · sobre_presupuesto · sin_stock · precio_alto (veredicto «esperar») · error_herramienta
Cada motivo replanifica una sola vez; el plan nuevo conserva los pasos ya hechos.

Cinco diagnósticos cambian el plan

Observación	Diagnóstico	Adaptación
Búsqueda con 0 resultados	**sin_resultados**	Términos más generales, sin filtro de precio
Todo cuesta más que el presupuesto	**sobre_presupuesto**	Gama inferior o alerta; informa cuánto falta
Todas las ofertas sin stock	**sin_stock**	Descarta y elige otra tienda
Tendencia dice «esperar»	**precio_alto**	No compra hoy; alerta al promedio histórico
Una herramienta falló	**error_herramienta**	Corrige parámetros y reintenta una vez

Memoria de corto y largo plazo

Corto plazo

Continuidad dentro de una tarea

- Historial del hilo en el checkpointer de LangGraph
- SQLite en local, Postgres con varias réplicas
- Ventana de 24 mensajes + resumen de lo recortado
- Cada hilo atado a su usuario

Largo plazo

Conocimiento entre conversaciones

- Preferencias, hechos y episodios con embedding
- Memoria núcleo: lo importante se carga siempre
- Búsqueda semántica; sin duplicados
- Aislada por usuario

puntaje = 0,75 · similitud + 0,15 · importancia/5 + 0,10 · recencia

Demo en vivo: cinco historias

1

Compra simple

consulta → razonamiento → escritura

2

Sin resultados

replan ×2 y alerta de precio

3

Precio inflado

el historial dice «esperar»

4

Otro día, otro hilo

recuerda «Prefiero Samsung»

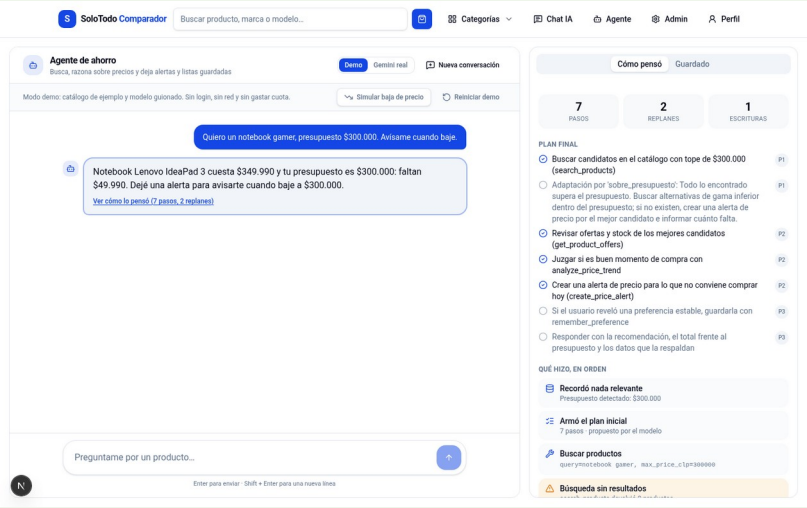
5

Bajó el precio

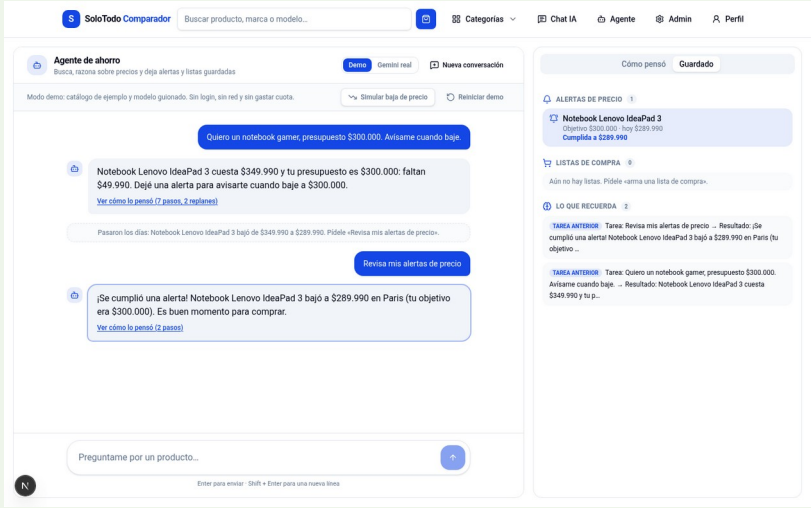
se cumple la alerta

```
.venv/bin/python scripts/demo_agente.py --live --embeddings gemini
```

La pantalla: se ve cómo piensa



Plan, herramientas y replanes en vivo



La alerta se cumple y queda guardada

Modo demo en http://localhost:3000/agente: sin login y sin gastar cuota

Evidencia

88

pruebas del agente

873

pruebas en todo el repositorio

11

herramientas: consulta, razonamiento y escritura

5

diagnósticos que replanifican

Gemini real: historias 1 a 3 completas, con replan por sin_resultados, sobre_presupuesto y precio_alto

Checkpointer: dos conexiones distintas comparten un mismo hilo en Postgres 16 real

Por qué estas decisiones

LangGraph	el flujo tiene ciclo (reflect → plan), estado y checkpointer; el orquestador previo no guardaba estado
Reglas en código	diagnóstico, tendencia y presupuesto se prueban sin red: 88 pruebas
Memoria núcleo	con embeddings locales «Recomiéndame un celular» no recuperaba «Prefiero Samsung»
Checkpointer Postgres	varias réplicas comparten los hilos (probado con Postgres 16 real)