DEFENSA TÉCNICA · EQUIPO 1

TodoBarato *AI*

Arquitectura de IA escalable y segura,
desplegada y medida en AWS.



NICOLÁS ESTEFANÍA · DIEGO TAPIA · ARIEL ESPINOZA

Un mismo producto, *tres nombres.*

SP DIGITAL · $149.990

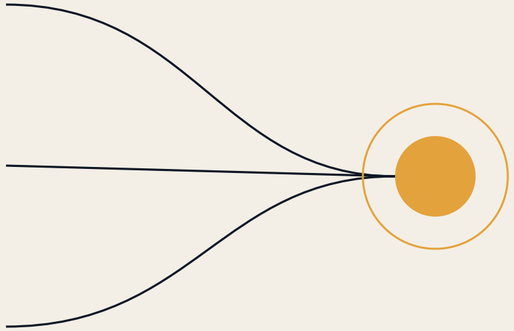
«ASUS Prime H610M-E D4 LGA1700»

PARIS · $159.990

«Placa Madre Asus H610M-E DDR4»

OTRA TIENDA · $155.000

«MB ASUS PRIME H610ME D4 mATX»



EL PROBLEMA

Cada tienda publica nombres, unidades y descripciones distintas. Comparar es lento para el comprador y caro para la empresa que vigila a su competencia.

PRODUCTO CANÓNICO

SKU · MPN · GTIN → IA solo si es ambiguo

01

Catálogo canónico

02

Asistente con evidencia

03

Agente de ahorro

Cinco metas *medibles.*

DISPONIBILIDAD

99,5%

mensual, tolerando la caída de una réplica o una zona

LATENCIA P95

<2s

en el catálogo, con carga real

ESCALADO

2 → 4

réplicas automáticas al 60 % de CPU

RPO · RTO

5 / 15

minutos de datos · de recuperación

COSTO

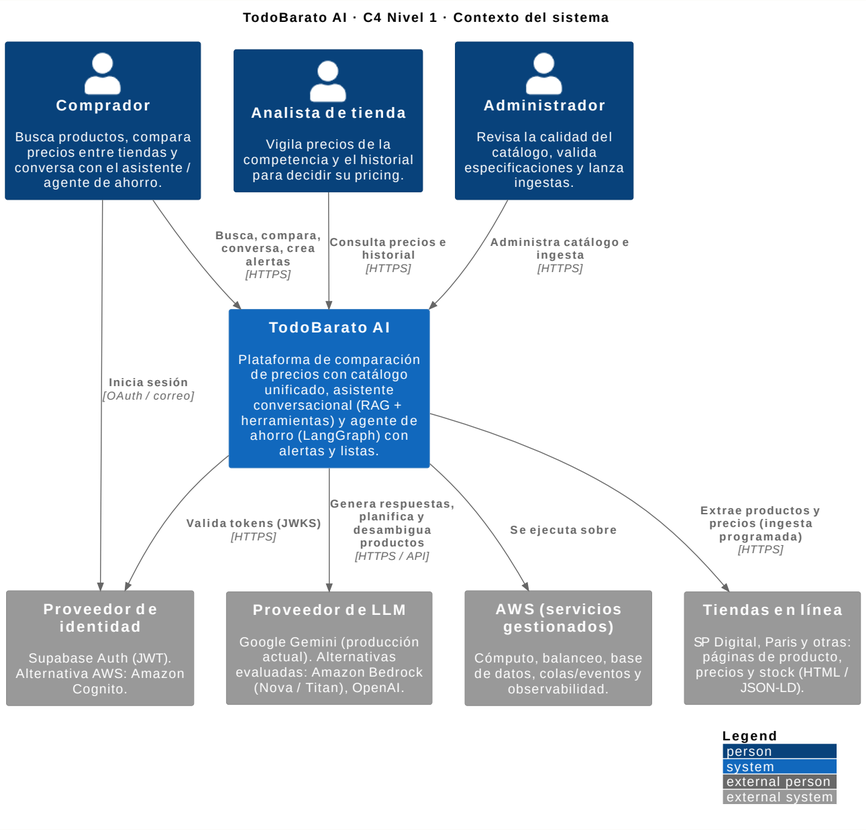
<200

USD al mes con 5.000 usuarios

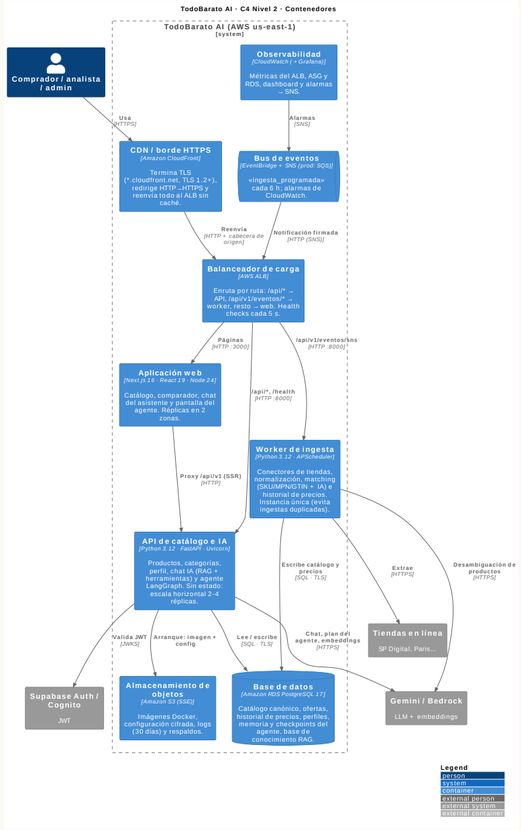
Cada meta tiene una medición en AWS al final de esta defensa.

Contexto y *contenedores.*

NIVEL 1 · CONTEXTO

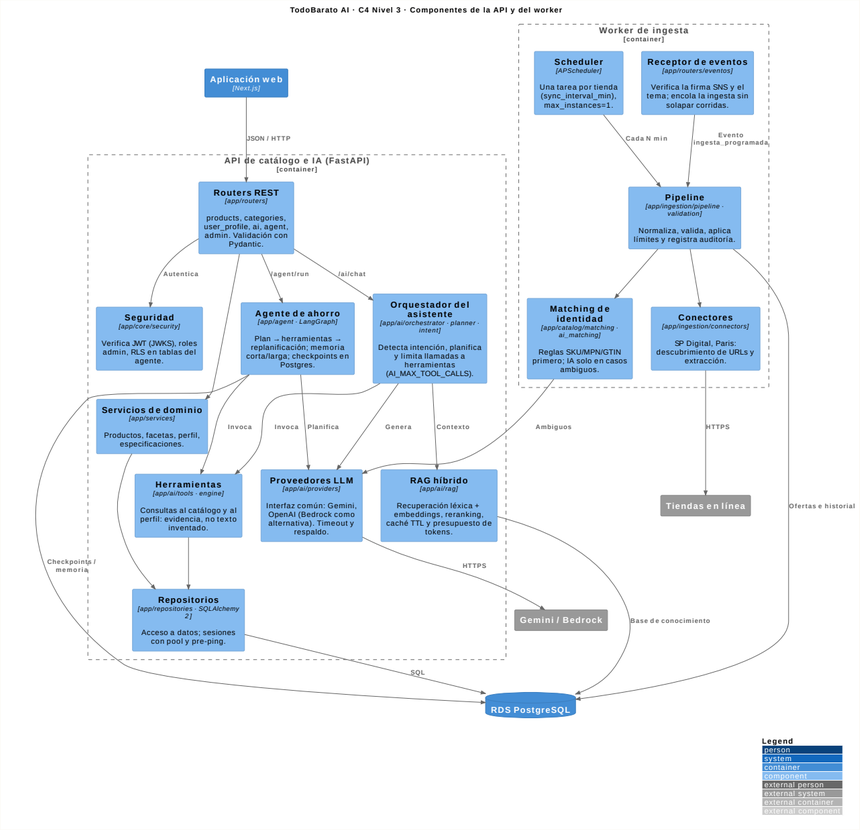


NIVEL 2 · CONTENEDORES



Componentes: *reglas primero.*

NIVEL 3 · API Y WORKER (MÓDULOS REALES DE APP/)



A · SIN ESTADO

Los checkpoints del agente viven en Postgres: cualquier réplica continúa la conversación.

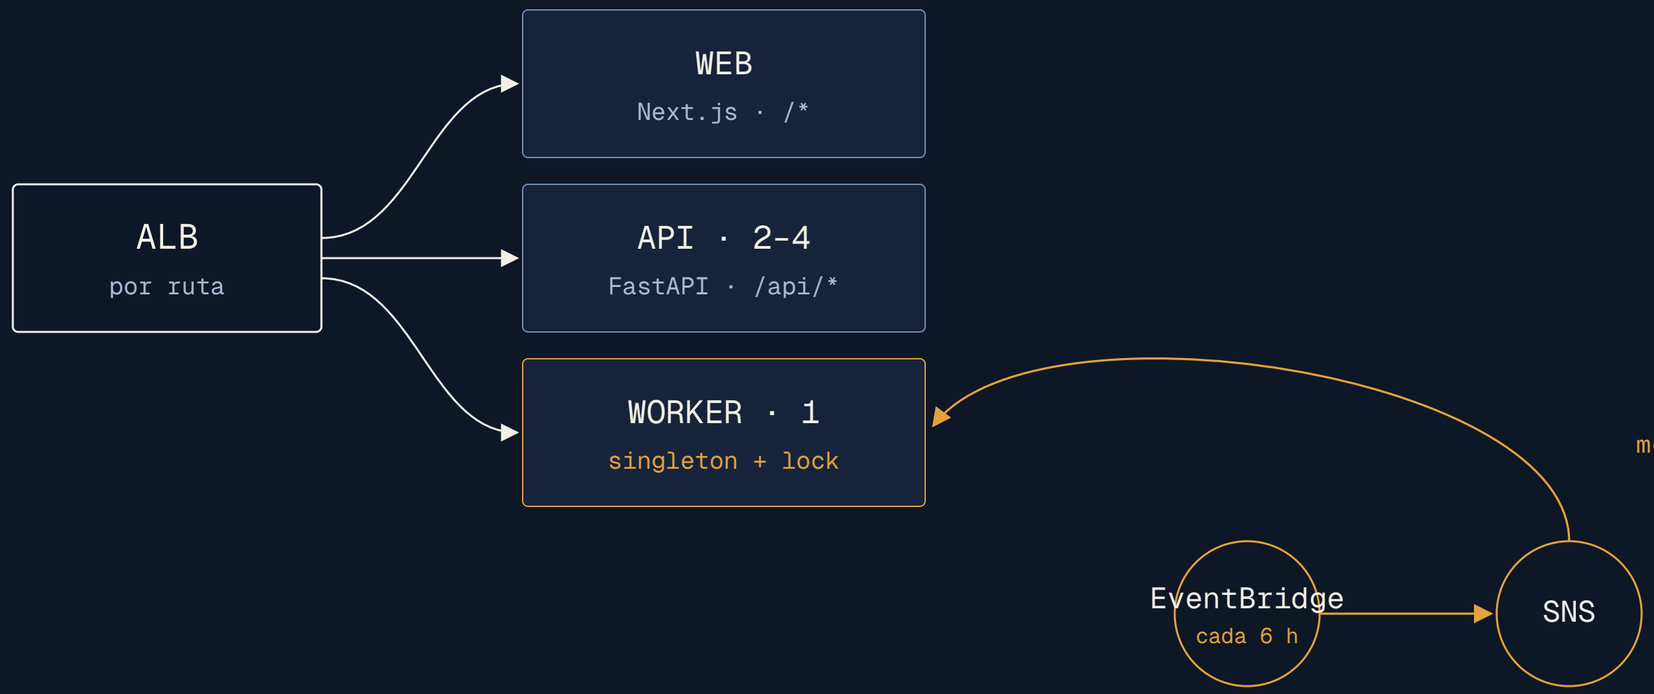
B · MATCHING HÍBRIDO

SKU, MPN y GTIN resuelven la identidad; el LLM solo decide lo ambiguo.

C · ACOTADO

Máx. 3 herramientas y 1.600 tokens de contexto por consulta.

Tres servicios. *Un evento* los desacopla.



MICROSERVICIOS

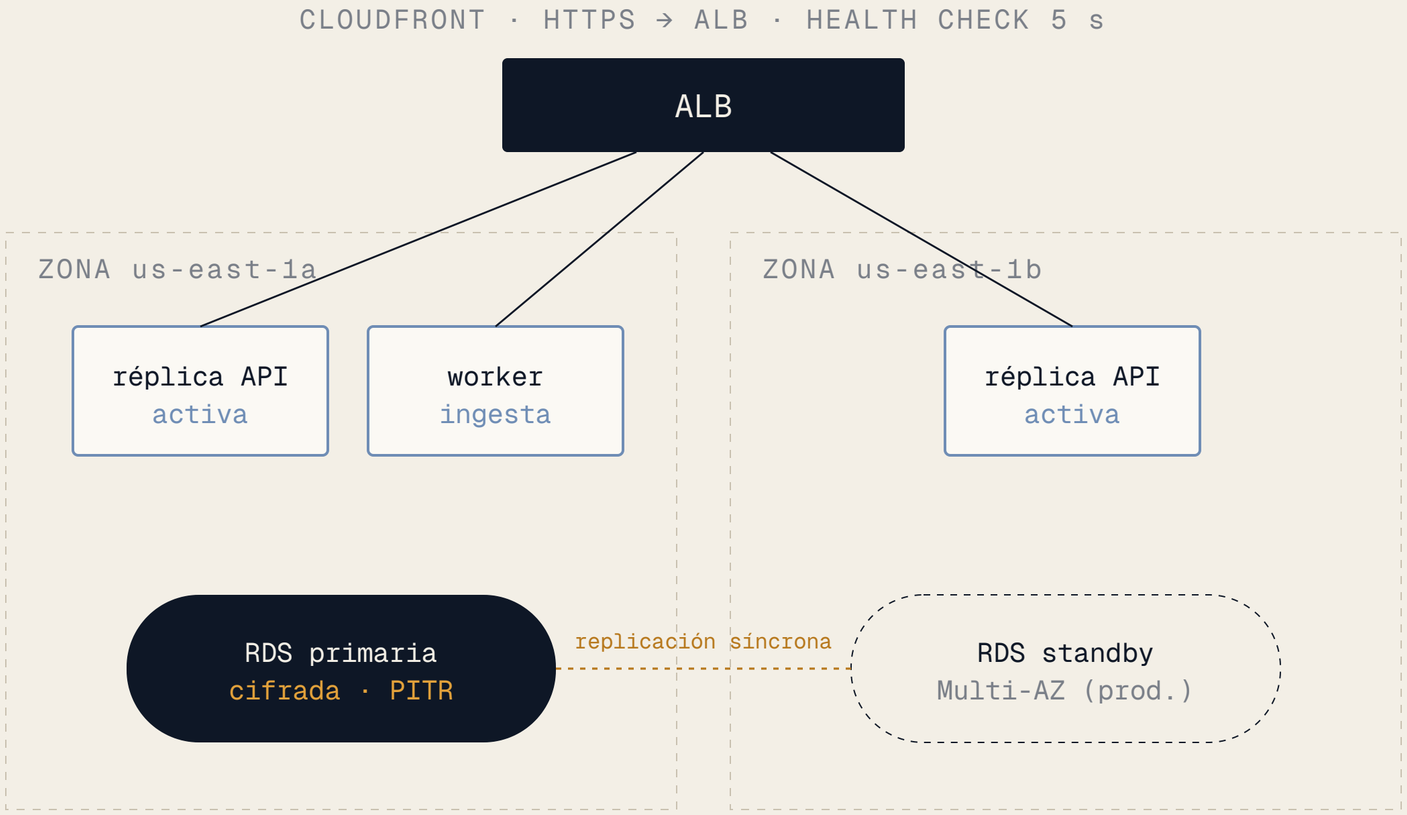
La búsqueda escala con los usuarios; la ingesta, con su calendario.

DEFECTO HALLADO AL DESPLEGAR

Con 2 réplicas la ingesta corría 2 veces. Se separó el worker.

`mensaje firmado → 202 → segundo plano`

Dos zonas. *Ninguna* es indispensable.



12 s — el ALB retira una réplica caída (medido)

219 s — el Auto Scaling la repone solo

5/15 — RPO · RTO en minutos (backups + PITR)

SEGURIDAD

SG encadenados, RDS privada con TLS, AES-256.

EFICIENCIA

2 réplicas por disponibilidad, no por carga: el pico es 2 req/s.

Lo que elegimos *y lo que no.*

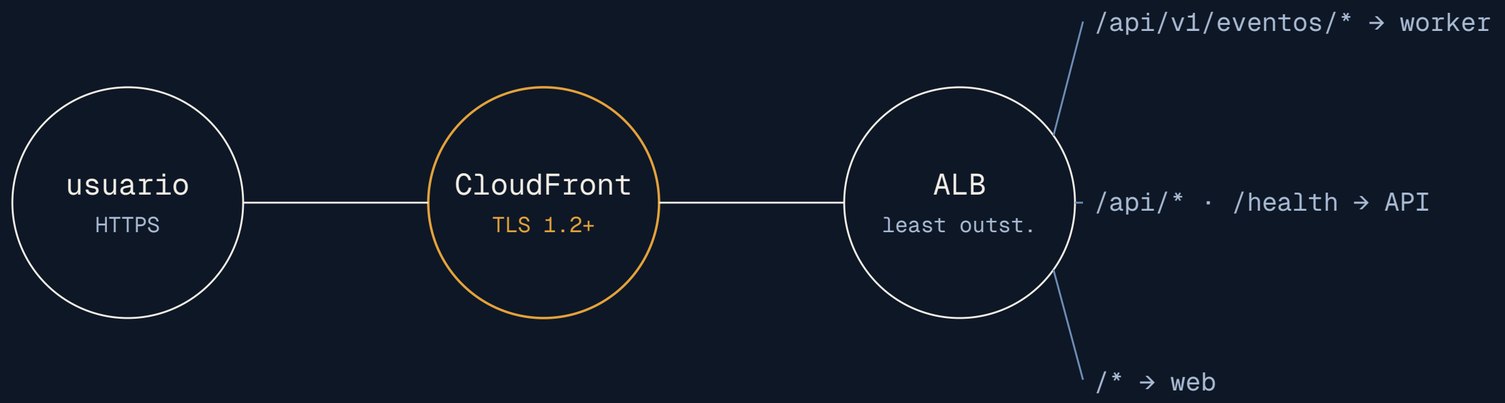
ELEGIDO	DESCARTADO	POR QUÉ
Tres servicios + eventos	~~Monolito con scheduler~~	Escalado independiente; sin ingesta duplicada.
ECS Fargate (producción)	~~EKS~~	Sin plano de control que operar, como decidió la EP1.
LLM por API	~~GPU propia~~	USD 55 contra USD 734 al mes: 13× más barato.
Least outstanding requests	~~Round robin~~	Las solicitudes duran entre 50 ms y 30 s.
Health check 5 s × 2	~~15 s × 3~~	Ventana de errores de 27 a 12 s (medido).
CloudFront + HTTPS	~~HTTP directo al ALB~~	Sin contexto seguro el chat fallaba en el navegador.

Contratos simples, *proveedores intercambiables.*

WEB ⇔ API	DISPARO DE INGESTA	ENTREGA	API ⇔ LLM	ESTADO DEL AGENTE
REST · JSON	**Eventos**	**SNS → SQS**	**Adapter**	**Postgres**
Esquemas Pydantic. GraphQL y gRPC no aportan a este volumen.	El worker responde 202 en ms; síncrono bloquearía la API minutos.	Firma verificada. En producción, cola durable con DLQ.	Gemini hoy, Bedrock Nova Lite mañana: una variable de entorno.	Checkpoints LangGraph: sin sesiones pegajosas en el balanceador.

FRAMEWORKS FastAPI · LangGraph · SQLAlchemy 2 + Alembic · Next.js · RAG híbrido

Del navegador a la réplica, *en tres saltos.*



CONTENEDORES

Docker multi-etapa, sin root, HEALTHCHECK. 469 MB la API.

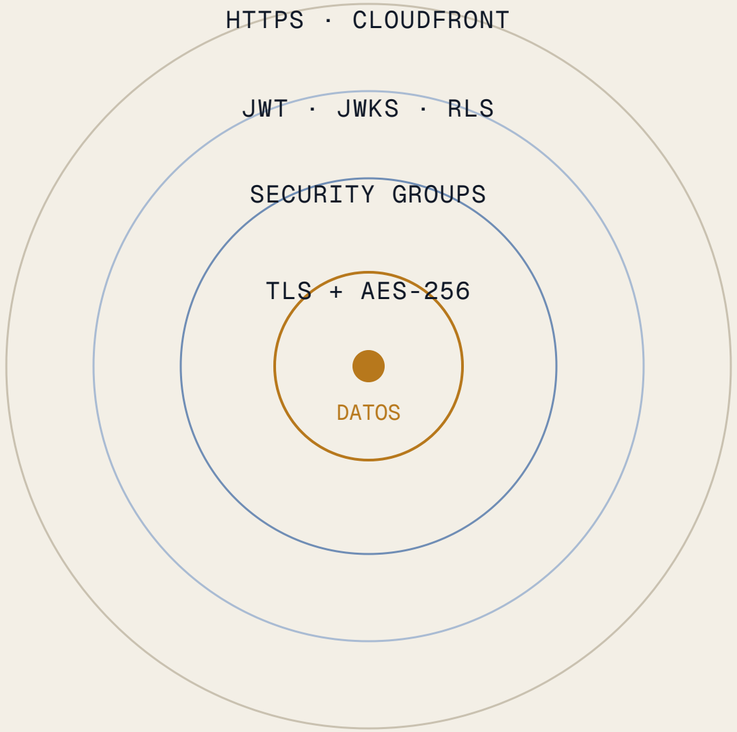
ORQUESTACIÓN (LAB)

Auto Scaling 2–4 por CPU 60 % en 2 zonas; rolling de a una réplica.

PRODUCCIÓN

ECS Fargate (como en la EP1), 2–6 tareas, rollback automático.

Capas que protegen, *alarmas que avisan.*



PLAN DE SEGURIDAD

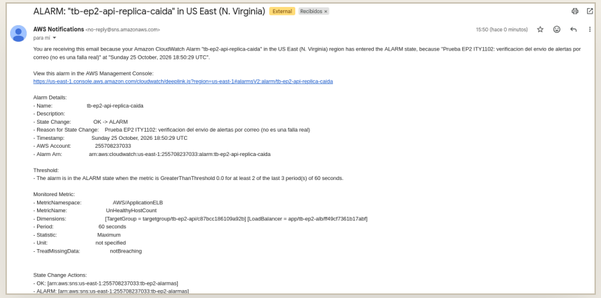
Secretos generados al desplegar, cifrados en un bucket privado; nunca en la imagen.

Eventos con firma de SNS verificada: un mensaje sin firma recibe 403.

Producción: Secrets Manager, Cognito y AWS WAF.

OBSERVABILIDAD

Dashboard CloudWatch, logs y 5 alarmas. La de réplica caída llegó por correo en el failover:



ALARM: "tb-ep2-api-replica-caida" in US East (N. Virginia) External Recibidos ×

AWS Notifications <no-reply@sns.amazonaws.com> 15:50 (hace 0 minutos)

para mí

You are receiving this email because your Amazon CloudWatch Alarm "tb-ep2-api-replica-caida" in the US East (N. Virginia) region has entered the ALARM state, because "Prueba EP2 ITY1102: verificacion del envio de alertas por correo (no es una falla real)" at "Sunday 25 October, 2026 18:50:29 UTC".

View this alarm in the AWS Management Console:
https://us-east-1.console.aws.amazon.com/cloudwatch/deeplink.js?region=us-east-1#alarmsV2:alarm/tb-ep2-api-replica-caida

Alarm Details:
- Name: tb-ep2-api-replica-caida
- Description:
- State Change: OK -> ALARM
- Reason for State Change: Prueba EP2 ITY1102: verificacion del envio de alertas por correo (no es una falla real)
- Timestamp: Sunday 25 October, 2026 18:50:29 UTC
- AWS Account: 255708237033
- Alarm Arn: arn:aws:cloudwatch:us-east-1:255708237033:alarm:tb-ep2-api-replica-caida

Threshold:
- The alarm is in the ALARM state when the metric is GreaterThanThreshold 0.0 for at least 2 of the last 3 period(s) of 60 seconds.

Monitored Metric:
- MetricNamespace: AWS/ApplicationELB
- MetricName: UnHealthyHostCount
- Dimensions: [TargetGroup = targetgroup/tb-ep2-api/87bcc186109a92fd] [LoadBalancer = app/tb-ep2-alb/ff49cf7361b17abf]
- Period: 60 seconds
- Statistic: Maximum
- Unit: not specified
- TreatMissingData: notBreaching

State Change Actions:
- OK: [arn:aws:sns:us-east-1:255708237033:tb-ep2-alarmas]
- ALARM: [arn:aws:sns:us-east-1:255708237033:tb-ep2-alarmas]

Medido, no supuesto.

43,9

REQ/S DEL CATÁLOGO · 2 RÉPLICAS

0,95 s

LATENCIA P95 · META < 2 S

0

ERRORES EN 1.999 SOLICITUDES

¿DÓNDE ESTÁ EL CUELLO DE BOTELLA? · CPU DURANTE LA CARGA

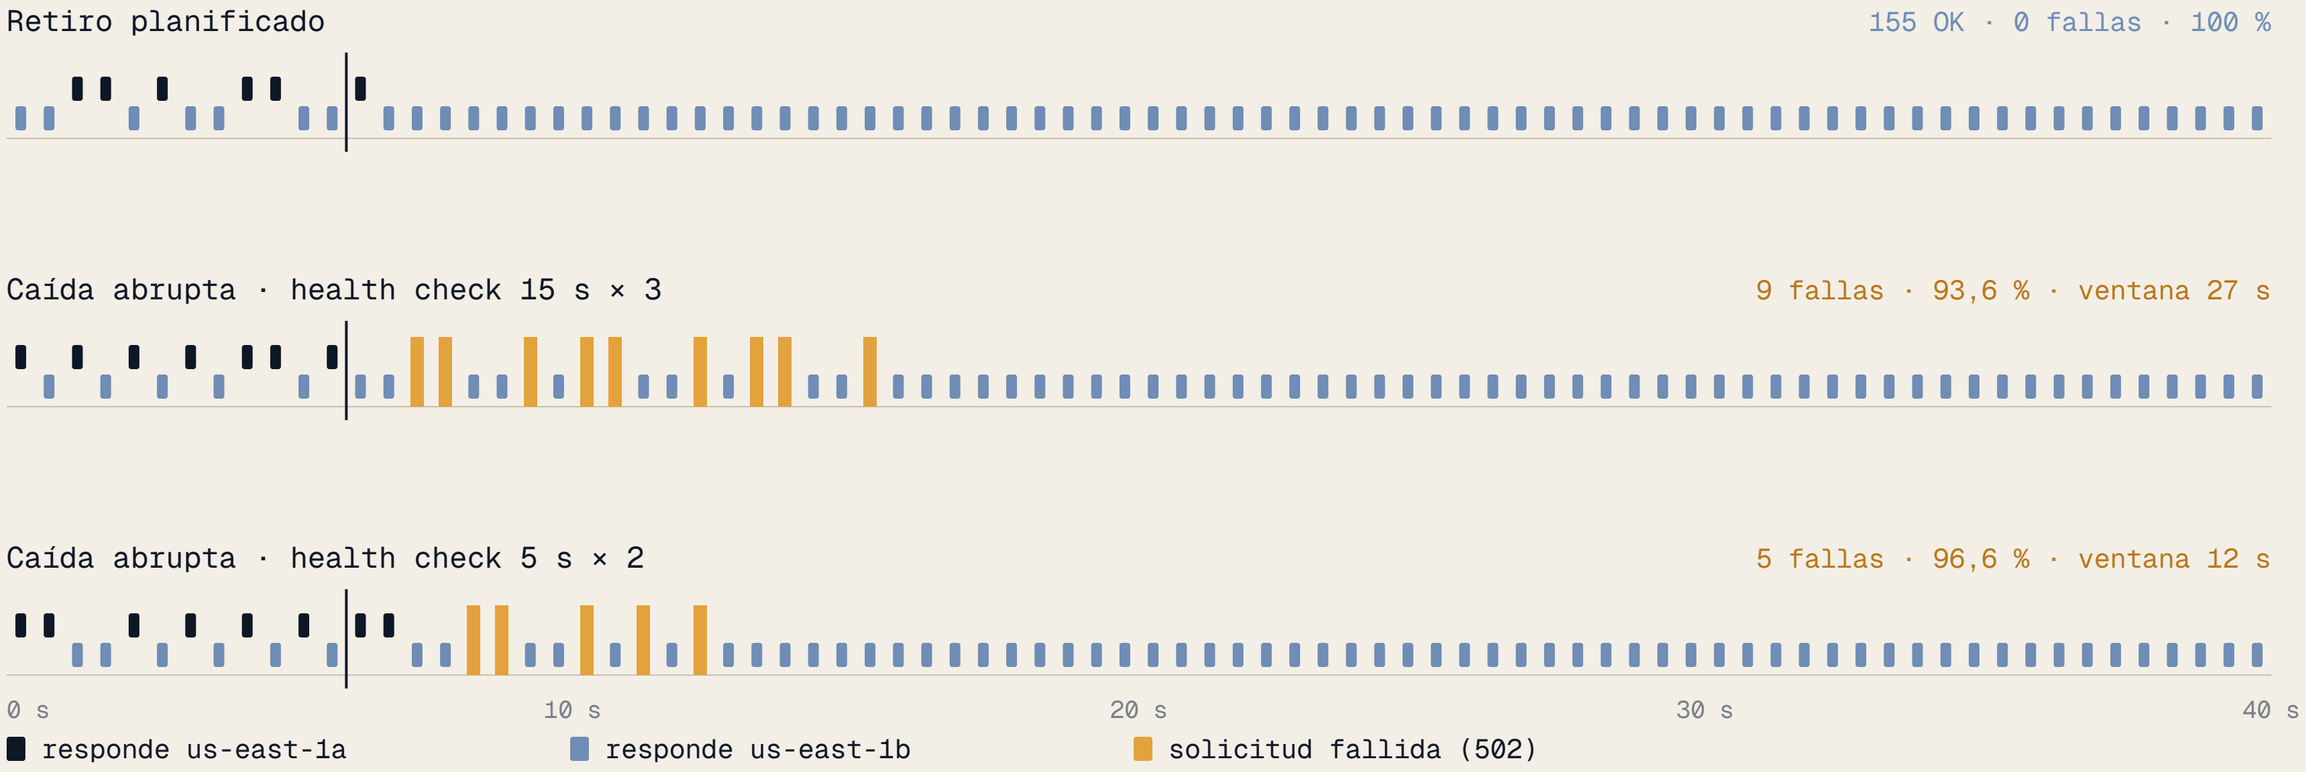


Se escala la API por CPU; la base queda en db.t4g.micro. Con 22 veces el pico estimado, sobra holgura.

HEY · 45 S · 20 CLIENTES CONCURRENTES · DESDE CHILE A US-EAST-1

Una réplica cae. *El servicio no.*

Cada marca es una consulta a /health cada 0,5 s · terminamos una réplica en la línea vertical



La GPU propia costaba *13 veces más.*

COSTO MENSUAL DE LA INFERENCIA · USD



120,44

USD/MES EN AWS · PRICING CALCULATOR

0

GPU O TPU: NO SE ENTRENA, SE INFIERE POR API

≈178

USD/MES TOTAL CON EL LLM · META < 200

T3.SMALL × 3 · RDS DB.T4G.MICRO MULTI-AZ · ALB · CLOUDWATCH · S3

Una arquitectura que se defiende *con mediciones.*

EP1 → EP2

Recursos e integración, lo que faltó, ahora medidos.

ESCALA

Tres servicios que crecen por separado, unidos por eventos.

RESISTE

Dos zonas, autocuración y alertas probadas en vivo.

SIGUIENTE

ECS Fargate, SQS, Secrets Manager, Cognito, Bedrock.



¿Preguntas?